

Reprodução Parcial e Estendida de "ChatGPT or Grammarly?": Comparando Sistemas de Correção Gramatical em Múltiplos Benchmarks

Gabriel Oliveira Rodrigues
Universidade Federal de Campina Grande
Campina Grande, Brasil
gabriel.rodrigues@copin.ufcg.edu.br

ABSTRACT

Grammatical Error Correction (GEC) é uma tarefa fundamental de Processamento de Linguagem Natural voltada à identificação e correção automática de erros gramaticais em textos escritos. Wu et al. [1] realizaram um dos primeiros estudos sistemáticos comparando o ChatGPT a duas ferramentas de referência — Grammarly e GECtoR [2] — sobre o benchmark CoNLL-2014 [3], encontrando desempenho inferior em métricas automáticas, porém competitivo em avaliação humana devido a um padrão de *over-correction*. O trabalho original, no entanto, apresenta limitações metodológicas relevantes: amostra reduzida, ausência de repetições, falta de testes estatísticos formais e não especificação da versão do modelo utilizado. Este artigo propõe um plano de reprodução parcial e estendida do estudo original, adicionando três sistemas (LanguageTool, Claude e DeepSeek), estendendo a avaliação para os benchmarks BEA-2019 [4] e JFLEG [5], e introduzindo repetições e testes estatísticos formais ausentes no trabalho original. Um kit de reprodução completo será disponibilizado publicamente para apoiar pesquisas futuras.

KEYWORDS

Correção de Erros Gramaticais, Grandes Modelos de Linguagem, Reprodutibilidade, Processamento de Linguagem Natural, Avaliação de Sistemas de PLN

1 INTRODUÇÃO

Grammatical Error Correction (GEC), ou Correção de Erros Gramaticais, é uma das tarefas mais fundamentais do Processamento de Linguagem Natural, com o objetivo de identificar e corrigir erros gramaticais em textos escritos. Dada sua posição como pilar da área, diversas aplicações surgiram ao longo dos anos para enfrentar essa tarefa, desde simples corretores ortográficos até sofisticados assistentes inteligentes de escrita, do uso geral e diário na escrita de e-mails e mensagens a ferramentas voltadas a nichos específicos, como corretores de redação, sistemas de texto para fala e tradução automática, entre outros. Entretanto, a maioria dessas aplicações ainda se fundamenta em técnicas e heurísticas simples, utilizando modelos estatísticos e abordagens baseadas em regras estáticas. A popularização dos modelos de linguagem em larga escala (*Large Language Models*, LLMs) ameaça mudar esse cenário, abrindo espaço para corretores treinados com *feedback* humano real, capazes de superar o desempenho de corretores tradicionais em GEC.

Wu et al. [1] estiveram entre os primeiros a investigar esse problema com uma abordagem sistemática, utilizando o ChatGPT para identificar e corrigir erros no CoNLL-2014 [3], um banco de dados

comumente utilizado para *benchmarking* em GEC. A investigação comparou o ChatGPT com duas outras ferramentas: Grammarly, um popular assistente de escrita disponível comercialmente, e GECtoR [2], um modelo de GEC baseado em RoBERTa pré-treinado e considerado estado da arte à época. Os resultados apontaram que, em métricas automáticas usuais, o ChatGPT se comportava de forma inferior aos demais modelos. Entretanto, um olhar mais atento revelou maior nuance: o modelo da OpenAI tendia a realizar *over-corrections*, modificando a frase além do esperado mas preservando o significado semântico — por exemplo, para a frase "*For an example, if exercising is helpful for family potential disease, we can always look for more chances for the family to go exercise*", a correção produzida foi "*For example, if exercise is helpful in preventing potential family diseases, we can always look for more opportunities for the family to exercise*" — evidenciando que o modelo apresentava desempenho competitivo com as demais ferramentas ao se avaliar sua utilidade em situações reais.

Apesar de suas contribuições, o trabalho original apresenta sérias limitações metodológicas. A versão do ChatGPT utilizada não foi declarada, e o experimento não especifica uma data ou *timeline*. Além disso, apenas 20 das frases corrigidas foram avaliadas por humanos, e o experimento como um todo utilizou apenas 100 das 1.300 frases disponíveis no *dataset*, sem repetições nem testes estatísticos formais. Por fim, apesar do curto intervalo entre a pesquisa original e o presente trabalho, o estado da arte de LLMs avançou consideravelmente desde então.

Este trabalho propõe uma reprodução parcial do estudo de Wu et al. [1], adicionando três ferramentas à comparação inicial (LanguageTool, Claude e DeepSeek), estendendo a avaliação para outros *benchmarks* comuns na área de GEC (BEA-2019 [4] e JFLEG [5]) e realizando repetições adicionais para garantir consistência entre os resultados, além de disponibilizar um kit de reprodução para pesquisas futuras.

2 METODOLOGIA

2.1 Objetivos da Reprodução

Este plano descreve a reprodução parcial e estendida do experimento de Wu et al. [1]. O experimento original será primeiramente reproduzido de forma fiel sobre o CoNLL-2014, estabelecendo uma linha de base comparável. Em seguida, o escopo será ampliado ao longo de três eixos principais: sistemas adicionais, *datasets* adicionais e rigor metodológico.

As contribuições adicionais em relação ao trabalho original são:

- **Sistemas adicionais:** inclusão do LanguageTool (*open source*, baseado em regras), Claude (Anthropic) e DeepSeek

(LLM *open source*), ampliando a comparação para seis sistemas no total e permitindo contrastar ferramentas proprietárias, comerciais e abertas.

- **Datasets adicionais:** extensão dos experimentos para BEA-2019 e JFLEG, os dois *datasets* mencionados como trabalho futuro no artigo original, verificando se os resultados se generalizam além do CoNLL-2014.
- **Repetições para LLMs:** cada sentença será processada 3 vezes por cada sistema estocástico (ChatGPT, Claude, DeepSeek), permitindo medir variabilidade intra-sistema e calcular intervalos de confiança — lacuna central do trabalho original.
- **Testes estatísticos formais:** aplicação do teste de Shapiro-Wilk para verificação de normalidade e testes de hipótese adequados, com cálculo de tamanho de efeito, ausentes no original.
- **Contextualização em jogos educacionais:** os resultados serão interpretados sob a ótica da aplicabilidade de sistemas de GEC como componente de *feedback* linguístico em jogos educacionais multilíngues, área de pesquisa do discente.

2.2 Hipóteses Testáveis

As hipóteses a seguir orientam o desenho experimental e a análise estatística. H1 constitui a âncora da reprodução; as demais representam contribuições originais do estudo.

H1 — Reprodução dos resultados originais: os sistemas determinísticos (GECToR, Grammarly) apresentam F0.5 superior ao ChatGPT sobre o CoNLL-2014, replicando os resultados de Wu et al. [1].

H2 — Over-correction entre LLMs: LLMs diferentes (ChatGPT, Claude, DeepSeek) apresentam padrões distintos de *over-correction*, evidenciando que esse comportamento é característico de cada modelo e não uma propriedade geral dos LLMs.

H3 — Variabilidade estocástica: LLMs apresentam variabilidade significativa de F0.5 entre execuções para a mesma entrada, ao contrário de GECToR e LanguageTool, que são determinísticos e produzem resultados idênticos em todas as execuções.

H4 — Degradação por comprimento: todos os LLMs testados apresentam degradação de F0.5 em sentenças longas em relação a sentenças curtas, porém em graus distintos entre si.

H5 — Generalização entre datasets: o ranqueamento relativo dos sistemas se mantém consistente entre CoNLL-2014, BEA-2019 e JFLEG, sugerindo que os resultados do original são generalizáveis para outros *benchmarks* de GEC.

2.3 Variáveis do Experimento

A Tabela 1 apresenta as variáveis independentes, dependentes e controladas do experimento.

2.4 Desenho Experimental

Tipo de desenho: fatorial completo com repetição para sistemas estocásticos.

Amostragem: 200 sentenças por *dataset*, selecionadas aleatoriamente com *seed* fixo e estratificadas em três grupos iguais por comprimento (curtas, médias, longas).

Table 1: Variáveis do experimento

Tipo	Variável	Valores / Descrição
Independente	Sistema de GEC	GECToR, Grammarly, ChatGPT, LanguageTool, Claude, DeepSeek
Independente	Dataset	CoNLL-2014, BEA-2019, JFLEG
Independente	Comprimento da sentença	Curta, Média, Longa
Dependente	Precisão (P)	TP / (TP + FP)
Dependente	Recall (R)	TP / (TP + FN)
Dependente	F0.5	Média harmônica ponderada (precisão com peso maior)
Controlada	Prompt	Único, fixo e idêntico para todos os LLMs
Controlada	Versões dos sistemas	Fixadas e documentadas antes do início do experimento
Controlada	Ferramenta de avaliação	Scorer oficial de cada dataset (CoNLL scorer, ERRANT)

Repetições: para os sistemas estocásticos (ChatGPT, Claude, DeepSeek), cada sentença será processada 3 vezes. Para GECToR e LanguageTool (determinísticos), uma única execução é suficiente. O Grammarly será consultado manualmente, seguindo a metodologia do artigo original.

Randomização: a ordem de apresentação das sentenças será randomizada para cada sistema.

Automação: todos os sistemas, exceto Grammarly, serão consultados via *script* automatizado. O Grammarly será consultado manualmente de forma iterativa, conforme o protocolo original.

2.5 Protocolo de Coleta de Métricas

- (1) Configurar o ambiente Docker e instalar todas as dependências com versões fixadas.
- (2) Baixar e preparar os três *datasets* (CoNLL-2014, BEA-2019, JFLEG) em formato padronizado.
- (3) Selecionar 200 sentenças por *dataset* com *seed* aleatório fixo, estratificadas por comprimento.
- (4) Executar GECToR e LanguageTool (automatizados, 1 execução por sentença).
- (5) Executar ChatGPT, Claude e DeepSeek via API (automatizado, 3 execuções por sentença por *dataset*).
- (6) Consultar Grammarly manualmente sobre as 200 sentenças do CoNLL-2014, iterativamente até estabilização, conforme metodologia original.
- (7) Registrar todas as saídas brutas em CSV estruturado (sistema, *dataset*, sentença, execução, saída).
- (8) Aplicar ERRANT e *scorers* oficiais para calcular P, R e F0.5 por sistema, *dataset* e estrato de comprimento.
- (9) Exportar resultados consolidados para análise estatística.

2.6 Análise Estatística

- Calcular média, desvio padrão e IC 95% do F0.5 para cada sistema, por *dataset* e por estrato de comprimento.
- Verificar a normalidade da distribuição dos *scores* com o teste de Shapiro-Wilk. Caso a normalidade seja confirmada, aplicar teste t pareado; caso contrário, aplicar Wilcoxon signed-rank (não paramétrico).
- Calcular o tamanho de efeito para todas as comparações pareadas entre sistemas: d de Cohen (paramétrico) ou r de Wilcoxon (não paramétrico), conforme o resultado do teste de normalidade.
- Calcular o coeficiente de variação (CV) entre as 3 repetições de cada LLM para quantificar a variabilidade estocástica (H3).
- Comparar o ranqueamento relativo dos sistemas entre os três *datasets* para verificar consistência (H5).
- Gerar *boxplots* comparativos por sistema, por *dataset* e por estrato de comprimento.

posição. A diferença absoluta entre sistemas é bem maior em F0.5 (CoNLL-2014 e BEA-2019) do que em GLEU (JFLEG), sugerindo que essa métrica é mais tolerante a variações de correção entre os sistemas.

2.7 Artefatos para Reprodução

Todos os artefatos serão disponibilizados publicamente em repositório GitHub ao final do experimento, incluindo:

- Script completo para execução automatizada do *pipeline* de experimentos.
- Script de consulta e registro manual do Grammarly, com instruções detalhadas.
- Scripts de análise estatística e geração de figuras.
- Dados brutos (*outputs* de todos os sistemas) em formato CSV.

2.8 Modelos Utilizados

Os seguintes modelos foram utilizados durante a pesquisa, nas seguintes datas:

- LanguageTool: languagetool-6.8 — 23/06/2026
- ChatGPT: gpt-4o — 23/06/2026
- Claude: claude-sonnet-4-6 — 23/06/2026
- DeepSeek: deepseek-chat (DeepSeek V3) — 23/06/2026
- GECToR: gector-2024-roberta-large — 23/06/2026
- Grammarly: versão online (app.grammarly.com), conta Grammarly Pro — 23/06/2026

3 RESULTADOS E DISCUSSÃO

3.1 Visão Geral dos Resultados

Em geral, nas métricas analisadas (F0.5 e *Generalized Language Evaluation Understanding*, GLEU), as ferramentas apresentam uma ordem clara de desempenho, com GECToR atingindo a melhor avaliação, seguido de Claude, DeepSeek, ChatGPT e LanguageTool. O Grammarly não pôde ser comparado em todos os testes dada sua falta de API funcional, mas, diferentemente da pesquisa original de Wu et al., ele apresentou desempenho inferior às LLMs nos testes aplicados.

A Tabela 2 evidencia essa hierarquia estável: GECToR lidera com folga em todas as métricas, seguido por Claude entre os sistemas estocásticos, DeepSeek e ChatGPT em posições intermediárias e próximas entre si, e LanguageTool consistentemente na última

Table 2: Resultados consolidados de F0.5 (CoNLL-2014 e BEA-2019) e GLEU (JFLEG) por sistema. Para os sistemas estocásticos (ChatGPT, Claude, DeepSeek), os valores correspondem à média $\pm$ desvio padrão de 3 execuções; GECToR, Grammarly e LanguageTool são determinísticos (execução única). Grammarly não foi avaliado em BEA-2019 e JFLEG por falta de API funcional.

Sistema	F0.5 — CoNLL-2014	F0.5 — BEA-2019	GLEU — JFLEG
GECToR	0,472	0,600	0,464
Grammarly	0,136	—	—
LanguageTool	0,059	0,059	0,400
ChatGPT	0,186 $\pm$ 0,004	0,123 $\pm$ 0,009	0,421 $\pm$ 0,001
Claude	0,210 $\pm$ 0,001	0,156 $\pm$ 0,003	0,423 $\pm$ 0,000
DeepSeek	0,190 $\pm$ 0,007	0,142 $\pm$ 0,004	0,421 $\pm$ 0,001

3.2 Reprodução dos Resultados Originais

Analisando os resultados do *dataset* CoNLL-2014, o mesmo utilizado no experimento de Wu et al., o GECToR apresenta o melhor desempenho, atingindo um *score* F0.5 de 0,472, confirmando os resultados originais. Entretanto, o Grammarly apresentou um desempenho dramaticamente pior, marcando apenas 0,136, ficando abaixo das três LLMs estudadas (Claude: 0,210; DeepSeek: 0,190; ChatGPT: 0,186), ranqueando acima apenas do LanguageTool (0,059). É possível que essa diferença seja resultado de mudanças internas no próprio Grammarly, que, desde 2023, incorporou mais elementos de Inteligência Artificial em suas correções [6]. Outra explicação é que, dada a falta de API e a necessidade de uma metodologia manual na correção via Grammarly, diferentes estratégias de *input* e correção tenham alterado o desempenho.

3.2.1 Testes Estatísticos Formais entre LLMs. Para complementar a análise descritiva acima, aplicamos testes de hipótese pareados entre os três LLMs, conforme definido na Seção 2.6. Como o teste de Shapiro-Wilk não rejeitou a normalidade em nenhuma das combinações sistema $\times$ *dataset* (Tabela 5, Seção 3.4), utilizamos o teste t pareado. A Tabela 3 resume os resultados.

O Claude superou o ChatGPT de forma estatisticamente significativa nos três *datasets* (CoNLL-2014: $t = -9,35$, $p = 0,011$; BEA-2019: $t = -5,10$, $p = 0,036$; JFLEG: $t = -4,45$, $p = 0,047$), todos com tamanho de efeito grande ($d > 4,9$). Já a comparação Claude vs. DeepSeek atingiu significância apenas no JFLEG ($t = 4,93$, $p = 0,039$), permanecendo marginal em CoNLL-2014 ($p = 0,055$) e BEA-2019 ($p = 0,066$), apontando que o desempenho do Claude sobre o DeepSeek, portanto, é consistente em magnitude mas não uniformemente significativa do ponto de vista estatístico, o que qualifica a afirmação de liderança “consistente” feita na Seção 3.7. Por fim, ChatGPT e DeepSeek trocam de posição relativa entre *datasets*: não há diferença significativa em CoNLL-2014 ($p = 0,437$) nem em JFLEG ($p = 0,980$, diferença negligenciável), mas em BEA-2019 o DeepSeek supera o ChatGPT significativamente ($t = -6,91$, $p = 0,020$). Esse padrão corrobora a observação da Seção 3.4 de que a estabilidade relativa entre ChatGPT e DeepSeek depende do *dataset* avaliado, e não é uma propriedade fixa dos modelos.

Também aplicamos o teste de Wilcoxon signed-rank entre cada LLM e os sistemas determinísticos (GECToR, Grammarly, LanguageTool). Em todos os 21 pares testados, a estatística foi 0,0 e o p-valor 0,25 — o menor p-valor teoricamente atingível pelo Wilcoxon

signed-rank com $n = 3$, independentemente da magnitude da diferença observada. Isso significa que o teste, embora corretamente aplicado, é estruturalmente incapaz de detectar significância nesse regime amostral, mesmo diante de diferenças de mais de 0,25 pontos de F0.5 entre GECToR e as LLMs. Por essa razão, H1 é sustentada não pelo teste de hipótese formal, mas pela não sobreposição dos intervalos de confiança de 95% (Tabela 4) entre o GECToR e qualquer LLM, já que sistemas determinísticos não possuem variância amostral e, portanto, IC de largura nula.

Table 3: Testes pareados entre LLMs ($n = 3$ execuções por sentença). Sistemas determinísticos (GECToR, Grammarly, Language-Tool) comparados via Wilcoxon signed-rank contra cada LLM apresentaram estatística = 0,0 e $p = 0,25$ em todos os 21 pares — o menor p-valor teoricamente atingível pelo Wilcoxon signed-rank com $n = 3$, não interpretável como ausência de diferença. As diferenças entre sistemas determinísticos e LLMs são confirmadas pela não sobreposição dos IC 95% (Tabela 4).

Dataset	Comparação	Média A	Média B	t	p	d de Cohen
CoNLL-2014	Claude vs. ChatGPT	0,2099	0,1858	-9,35	0,0112	7,54
CoNLL-2014	Claude vs. DeepSeek	0,2099	0,1899	4,10	0,0548	3,88
CoNLL-2014	ChatGPT vs. DeepSeek	0,1858	0,1899	-0,96	0,4369	0,70
BEA-2019	Claude vs. ChatGPT	0,1555	0,1232	-5,10	0,0363	5,14
BEA-2019	Claude vs. DeepSeek	0,1555	0,1423	3,70	0,0658	4,04
BEA-2019	ChatGPT vs. DeepSeek	0,1232	0,1423	-6,91	0,0203	2,90
JFLEG (GLEU)	Claude vs. ChatGPT	0,4233	0,4207	-4,45	0,0470	4,97
JFLEG (GLEU)	Claude vs. DeepSeek	0,4233	0,4207	4,93	0,0388	2,69
JFLEG (GLEU)	ChatGPT vs. DeepSeek	0,4207	0,4207	0,03	0,9799	0,03

3.3 Over-Correction entre LLMs

O comportamento de *over-correction* identificado por Wu et al. [1] não é diretamente mensurável pelo F0.5, que não mede a natureza das edições. Uma verdadeira análise do comportamento de *over-correction* necessitaria análises manuais das mais de 7.000 correções realizadas. Entretanto, como aproximação indireta, comparamos a relação entre precisão e *recall* de cada LLM, na qual uma tendência a corrigir além do necessário se reflete como *recall* superior à precisão, calculado como *over-score* (valor de *recall* – valor de precisão).

No CoNLL-2014, o ChatGPT recebeu um *over-score* de 0,011, o DeepSeek recebeu 0,005 e o Claude recebeu 0,004, um resultado comparativamente pequeno em relação ao BEA-2019, no qual as três LLMs receberam *over-score* de 0,116 para o ChatGPT, 0,119 para o DeepSeek e 0,121 para o Claude.

Isso demonstra suporte parcial para H2, evidenciando *over-correction* generalizada entre as LLMs, mas com um pequeno grau de variação entre diferentes modelos, menor que a variação entre *datasets*. Isso sugere que o problema de *over-correction* depende menos da arquitetura dos modelos em si e é possivelmente mais sensível às características dos *datasets* e frases estudadas.

Uma análise completa de H2 exigiria uma categorização por tipo de erro (ortografia, concordância, pontuação, estilo, etc.), o que o F0.5 não captura. O Grammarly, por ser consultado manualmente através de sua interface, permite nativamente esse tipo de categorização (dividindo seus erros em “erros críticos” e “melhorias de acurácia e clareza”), uma granularidade que as LLMs consultadas via API não fornecem sem *prompting* adicional. A ausência dessa taxonomia de erro no *pipeline* atual é reconhecida como uma limitação e é retomada na Seção 5.

3.4 Variabilidade Estocástica

Diferentemente de GECToR e LanguageTool, cujas 3 repetições produziram exatamente o mesmo resultado em todos os casos, confirmando a parte determinística de H3, os três LLMs apresentaram variabilidade não nula entre execuções para a mesma sentença, mesmo com temperatura configurada para o mínimo permitido pela API de cada serviço. A Tabela 4 resume o coeficiente de variação (CV) e o intervalo de confiança de 95% para cada LLM em cada *dataset*.

O Claude foi o sistema mais estável entre os três modelos, independentemente do *dataset*, mantendo o CV sempre abaixo de 1,7%, enquanto ChatGPT e DeepSeek apresentaram menos consistência, trocando de posições entre *datasets*, reforçando a hipótese de que desempenho e estabilidade em tarefas de GEC não dependem unicamente do modelo, mas também das características do *dataset* avaliado.

Essa análise expõe uma das maiores vulnerabilidades do experimento original de Wu et al. [1], que optou por rodar as correções apenas uma vez por sentença.

Aplicamos também o teste de Shapiro-Wilk sobre as 3 repetições de cada sistema estocástico em cada *dataset*, conforme previsto no protocolo estatístico (Seção 2.6). A Tabela 5 resume os resultados.

Em nenhuma das 9 combinações sistema×*dataset* o teste rejeitou a hipótese de normalidade, o que, segundo o protocolo definido na Seção 2.6, justifica o uso do teste t pareado (em vez do Wilcoxon signed-rank) nas comparações estatísticas entre sistemas. É importante notar, no entanto, que com apenas $n = 3$ observações por grupo o teste de Shapiro-Wilk tem poder estatístico muito baixo. A ausência de rejeição da normalidade aqui é esperada mesmo que a distribuição subjacente não seja de fato normal, e não deve ser lida como uma confirmação forte de normalidade. Essa limitação é retomada na Seção 5.2.

Table 4: Média, desvio padrão, coeficiente de variação (CV) e intervalo de confiança de 95% do F0.5 (CoNLL-2014, BEA-2019) e do GLEU (JFLEG) para os sistemas estocásticos, calculados sobre 3 execuções por sentença.

Sistema / Dataset	Média	DP	CV (%)	IC 95%
ChatGPT — CoNLL-2014	0,186	0,004	2,33	[0,175; 0,197]
Claude — CoNLL-2014	0,210	0,001	0,64	[0,207; 0,213]
DeepSeek — CoNLL-2014	0,190	0,007	3,78	[0,172; 0,208]
ChatGPT — BEA-2019	0,123	0,009	6,90	[0,102; 0,144]
Claude — BEA-2019	0,156	0,003	1,70	[0,149; 0,162]
DeepSeek — BEA-2019	0,142	0,004	2,68	[0,133; 0,152]
ChatGPT — JFLEG (GLEU)	0,421	0,001	0,14	[0,419; 0,422]
Claude — JFLEG (GLEU)	0,423	0,000	0,10	[0,422; 0,424]
DeepSeek — JFLEG (GLEU)	0,421	0,001	0,30	[0,418; 0,424]

Table 5: Estatística W e p-valor do teste de Shapiro-Wilk para as 3 repetições de cada LLM em cada *dataset*. Em todos os 9 casos, $p > 0,05$, não havendo evidência para rejeitar a hipótese de normalidade.

Sistema / Dataset	W (Shapiro-Wilk)	p-valor	Normal. ($p > 0,05$)
ChatGPT — CoNLL-2014	0,9626	0,6286	Sim
Claude — CoNLL-2014	0,8665	0,2855	Sim
DeepSeek — CoNLL-2014	0,9929	0,8385	Sim
ChatGPT — BEA-2019	0,9998	0,9741	Sim
Claude — BEA-2019	0,8547	0,2530	Sim
DeepSeek — BEA-2019	0,9643	0,6369	Sim
ChatGPT — JFLEG (GLEU)	0,7996	0,1135	Sim
Claude — JFLEG (GLEU)	0,9651	0,6412	Sim
DeepSeek — JFLEG (GLEU)	0,9747	0,6952	Sim

3.5 Degradação por Comprimento

A estratificação por comprimento de sentença, disponível para o *dataset* JFLEG (métrica GLEU), está resumida na Tabela 6.

Foi observado que a qualidade das correções, avaliada pela pontuação GLEU média, não se deteriora em sentenças longas em relação a sentenças curtas, contrariando o previsto na H4. Apesar de apresentar um leve padrão em U invertido, com sentenças médias apresentando a maior pontuação GLEU média, as sentenças médias ainda se comportam apenas ligeiramente diferentes das demais, alcançando uma diferença máxima de aproximadamente 0,010 de GLEU, próxima a ruído estatístico.

Consideramos H4 rejeitada com base na evidência disponível. Uma explicação plausível é que o GLEU, sendo uma métrica de sobreposição n-grama sensível ao comprimento total do texto, tende a compensar: sentenças mais longas normalmente contêm mais erros no texto de entrada, o que oferece às LLMs mais oportunidades de fazer correções corretas e, assim, mais n-gramas de acerto para inflar a métrica, contrabalançando qualquer degradação real de qualidade linguística.

Table 6: GLEU médio por estrato de comprimento (curtas, médias, longas) para os três LLMs no JFLEG.

Sistema	Curtas (≤ 17 pal.)	Médias (18–25 pal.)	Longas (> 25 pal.)
ChatGPT	0,409	0,416	0,406
Claude	0,408	0,416	0,409
DeepSeek	0,408	0,415	0,407

3.6 Generalização entre Datasets

Restringindo a comparação aos cinco sistemas testados nos três *datasets* (excluindo o Grammarly, avaliado apenas no CoNLL-2014), o ranqueamento relativo é apresentado na Tabela 7.

Os resultados forneceram forte suporte para H5, apresentando ranqueamento idêntico entre os *datasets* CoNLL-2014 e BEA-2019. A análise do *dataset* JFLEG apresentou resultados semelhantes, com os dois extremos se mantendo constantes, diferindo apenas nas posições dos modelos ChatGPT e DeepSeek, que empataram na avaliação por GLEU. Isso é consistente com o observado na Seção 3.1: o GLEU comprime as diferenças absolutas entre sistemas de forma muito mais acentuada do que o F0.5, tornando distinções finas entre modelos de desempenho próximo mais difíceis de detectar nessa métrica, ainda que a hierarquia geral entre categorias se mantenha igual.

Em suma, há fortes evidências que apontam para a confirmação de H5, reforçando a conclusão central de Wu et al. de que LLMs de propósito geral ocupam uma posição intermediária competitiva frente a corretores tradicionais de GEC.

Table 7: Ranqueamento dos sistemas por *dataset*, com o valor da métrica correspondente entre parênteses.

Posição	CoNLL-2014	BEA-2019	JFLEG (GLEU)
1°	GECToR (0,472)	GECToR (0,600)	GECToR (0,464)
2°	Claude (0,210)	Claude (0,156)	Claude (0,423)
3°	DeepSeek (0,190)	DeepSeek (0,142)	ChatGPT $\approx$ DeepSeek (0,421)
4°	ChatGPT (0,186)	ChatGPT (0,123)	ChatGPT $\approx$ DeepSeek (0,421)
5°	LanguageTool (0,059)	LanguageTool (0,059)	LanguageTool (0,400)

3.7 Discussão Geral

Entre os achados desta reprodução parcial e estendida do experimento de Wu et al. [1], três narrativas se apresentam com mais clareza:

- (1) GECToR, quando avaliado com métricas automáticas, mantém-se o claro vencedor quando comparado a LLMs e outras ferramentas, superando o segundo colocado por mais de 0,26 pontos no CoNLL-2014 e mais de 0,44 pontos no BEA-2019 — a maior diferença entre colocados — confirmando H1 e reafirmando a conclusão original de Wu et al., mesmo três anos e várias gerações de LLM depois.
- (2) Entre as LLMs, o Claude liderou consistentemente em todos os *datasets* e métricas testadas, seja em qualidade ou estabilidade (H3).
- (3) Por fim, o desempenho do Grammarly não se manteve entre a pesquisa original e a replicação, ficando atrás de todas as três LLMs testadas e superando apenas o LanguageTool. Como discutido na Seção 3.2, essa divergência provavelmente reflete tanto mudanças no próprio produto Grammarly desde 2023 (que passou a incorporar mais componentes de IA generativa em suas sugestões) quanto diferenças metodológicas na consulta manual, e não uma falha de reprodução em si. Entretanto, é inegável que a ferramenta não conseguiu apresentar o mesmo desempenho anterior.

Discutindo os resultados sob o contexto do uso das ferramentas analisadas como componente de *feedback* linguístico em jogos educacionais multilíngues, é importante lembrar que o sistema não deve se basear apenas no F0.5 ou no GLEU *score*. O GECToR, apesar de apresentar o melhor desempenho nas métricas estudadas, se mantém uma ferramenta determinística, altamente aperfeiçoada para correção gramatical rígida na língua inglesa, comprometendo sua capacidade de providenciar *feedback* linguístico formativo, explicativo e de qualidade para estudantes e jogadores, além de não ser apto para lidar com diferentes tipos de erros ou erros em outros idiomas. Essas deficiências vistas no GECToR são as maiores vantagens vistas no uso de LLMs, que, apesar de não apresentarem a mesma qualidade, apresentam resultados satisfatórios com um maior grau de flexibilidade, podendo gerar explicações em linguagem natural, diferenciar tipos de erros e se adaptar ao tom e nível do jogador ou estudante.

Entre as LLMs estudadas, o Claude apresentou os melhores resultados nas métricas automáticas e a maior estabilidade entre execuções. Em um sistema lúdico educacional, a capacidade de providenciar *feedback* acessível e consistente é uma ferramenta

importante, que melhora a experiência e confiança do usuário, sugerindo então o uso de uma arquitetura híbrida, com GECToR determinístico para lidar com erros de baixo nível e Claude para gerar *feedback* complementar.

4 REPRODUTIBILIDADE

Diferentemente da Seção 2.7, que descreveu os artefatos *planejados* para reprodução, esta seção documenta o ambiente de execução *efetivamente utilizado* na coleta de dados de 23/06/2026, incluindo divergências entre o que foi originalmente planejado e o que foi de fato confirmado.

4.1 Ambientes de Execução

O experimento envolveu três ambientes de execução distintos e não intercambiáveis, resumidos na Tabela 8.

Table 8: Ambientes de execução utilizados na coleta de dados.

Ambiente	Natureza	Papel
gector-dev	Container Docker (GPU)	Correção determinística (GECToR)
languagetool	Container Docker (Java)	Servidor de correção baseado em regras
Máquina local	Windows, Python 3.12	Consulta a APIs de LLM e análise

GECToR (gector-dev). As dependências foram obtidas via `pip freeze` executado diretamente no container, incluindo o *stack* CUDA completo, o que confirma a disponibilidade de GPU nesse ambiente. Como a coleta de dados em si foi executada com um *patch* de `map_location='cpu'` no carregamento do *checkpoint*, deixamos explícito que a presença de GPU no container não é um requisito de reprodução, apenas uma característica do ambiente onde o *freeze* foi gerado. Uma segunda instalação do GECToR (mesmo *commit*) foi identificada na máquina local do autor durante a auditoria deste ambiente; essa cópia foi confirmada como uso exclusivo de testes de desenvolvimento, não participou da coleta oficial, e foi por isso excluída da documentação de dependências.

LanguageTool. Por se tratar de um servidor Java e não de um pacote Python, não há `pip freeze` equivalente. A versão (6.8, *build* de 15/06/2026, edição não-*premium*) foi confirmada consultando o campo `software` da própria resposta da API HTTP do servidor em execução, e não a partir de metadados da imagem Docker. A ausência de recursos *premium* é registrada explicitamente, pois pode ser um fator de confusão na posição consistentemente inferior do LanguageTool nas comparações da Seção 3.

Consulta a APIs e análise (máquina local). Este ambiente concentra as bibliotecas de consulta às APIs de LLM (`openai`, `anthropic`) e de análise estatística. Ao contrário dos dois ambientes anteriores,

trata-se da máquina de uso diário do autor (Python 3.12, Windows), e não de um *container* isolado. Essa divergência em relação ao desenho original de três ambientes isolados (Seção 2.7) é registrada aqui por transparência: o `pip freeze` desse ambiente também revelou pacotes de projetos não relacionados a este experimento, confirmados pelo autor como pertencentes a outras atividades e por isso omitidos do arquivo de dependências final.

4.2 Artefatos Disponibilizados

Os seguintes artefatos de ambiente, referenciados nesta seção, compõem o kit de reprodução público mencionado na Seção 2.7 e na Conclusão:

- `requirements-gector.txt` — *freeze* confirmado do ambiente `gector-dev`.
- `requirements-analysis.txt` — dependências de consulta a APIs de LLM e análise estatística, com versões confirmadas e assumidas explicitamente distinguidas.
- `scripts` — os códigos utilizados.
- `data` — os datasets utilizados na pesquisa, junto dos outputs gerados pelos scripts.

O kit está disponível em: <https://github.com/GabrielRodrigues-42/Reprodu-o-Parcial-e-Estendida-de-ChatGPT-or-Grammarly->

5 AMEAÇAS À VALIDADE

5.1 Validade de Constructo

As métricas F0.5 (CoNLL-2014, BEA-2019) e GLEU (JFLEG) capturam sobreposição lexical/estrutural entre a correção proposta e a referência, mas não medem diretamente a qualidade percebida por um usuário humano, nem distinguem *over-corrections* semanticamente aceitáveis (como no exemplo de Wu et al. discutido na Introdução) de correções genuinamente erradas. Isso significa que o desempenho relativamente baixo das LLMs em F0.5 (Seção 3.2) pode subestimar sua utilidade prática, replicando uma limitação já identificada no artigo original e não resolvida por esta reprodução.

A ausência de uma taxonomia de erro (gramática, pontuação, estilo, léxico) no *pipeline* automatizado, apontada na Seção 3.3, também é uma ameaça de constructo para H2, e o *over-score* usado como *proxy* de *over-correction* é uma medida indireta e pode não capturar completamente o fenômeno definido qualitativamente por Wu et al.

5.2 Validade Interna

O uso de um *prompt* único e fixo para os três LLMs (ChatGPT, Claude, DeepSeek), embora necessário para comparabilidade, favorece sistematicamente modelos cujo estilo de resposta padrão se alinha melhor à formulação escolhida, o que é uma fonte conhecida de viés em comparações entre LLMs. Diferenças de desempenho entre modelos podem refletir, em parte, sensibilidade a *prompt* e não apenas capacidade de correção gramatical.

A consulta ao Grammarly foi feita manualmente e em execução única (sem repetições), diferentemente dos demais sistemas estocásticos. Isso impede o cálculo de variabilidade para o Grammarly e introduz possível viés do avaliador humano na estratégia de *input*, discutido como explicação alternativa para seu desempenho na Seção 3.2.

O tamanho amostral de 200 sentenças por *dataset*, embora maior que as 100 sentenças usadas por Wu et al. [1], ainda representa uma fração dos mais de 1.300 pares disponíveis no CoNLL-2014 e é obtido a partir de um único *seed* de amostragem aleatória. Um *seed* diferente poderia gerar uma amostra com composição de erros distinta o suficiente para alterar os resultados, embora seja improvável que altere o ranqueamento relativo dado o tamanho das diferenças observadas entre GECToR e os demais sistemas.

O teste de Shapiro-Wilk aplicado às 3 repetições de cada LLM (Seção 3.4, Tabela 5) não rejeitou a normalidade em nenhuma das 9 combinações *sistema*×*dataset* ($p > 0,05$ em todos os casos), o que respaldou o uso do teste t pareado conforme o protocolo da Seção 2.6. No entanto, com apenas $n = 3$ observações por grupo, o Shapiro-Wilk tem poder estatístico muito baixo: a não rejeição da normalidade é o resultado esperado mesmo quando a distribuição subjacente não é de fato normal, de modo que os resultados devem ser interpretados como indicativos, não conclusivos.

5.3 Validade Externa

Os três *benchmarks* utilizados (CoNLL-2014, BEA-2019, JFLEG) cobrem primariamente erros de aprendizes de inglês como segunda língua em contextos acadêmicos ou de redação geral. A generalização observada em H5 (Seção 3.6) é, portanto, uma generalização dentro da língua inglesa e de gêneros textuais próximos entre si, e não podemos afirmar que o mesmo ranqueamento se manteria para outros idiomas — um ponto especialmente relevante dada a motivação declarada deste trabalho em aplicações de jogos educacionais multilíngues (Seção 2.1).

As versões dos modelos de LLM utilizadas (ChatGPT, Claude, DeepSeek) representam um instante específico no tempo; como esses sistemas são atualizados continuamente pelos provedores sem aviso prévio, os resultados absolutos reportados aqui têm validade temporal limitada e podem não se replicar exatamente em versões futuras dos mesmos modelos.

6 CONCLUSÃO

Este trabalho realizou uma reprodução parcial e estendida do experimento de Wu et al. [1], que comparou o ChatGPT a corretores gramaticais tradicionais sobre o CoNLL-2014. A reprodução fiel do núcleo do experimento original confirmou H1, apontando que sistemas determinísticos especializados, representados pelo GECToR, seguem superando LLMs de propósito geral por uma margem significativa em métricas automáticas mesmo após três anos e diversas gerações de modelos desde a publicação original.

Ao estender a comparação com três sistemas adicionais (LanguageTool, Claude e DeepSeek), dois *benchmarks* adicionais (BEA-2019 e JFLEG) e repetições para os sistemas estocásticos, este trabalho também produziu achados que vão além do trabalho original. O Claude se destacou como a LLM de melhor desempenho e maior estabilidade entre execuções em todas as condições testadas. Quanto às hipóteses adicionais, o comportamento de *over-correction* mostrou-se mais sensível ao *dataset* avaliado do que ao modelo em si, o que suporta parcialmente H2. A variabilidade estocástica das LLMs foi confirmada e quantificada, com CVs de até 6,9% em um único *dataset*, justificando a adoção de repetições como prática

padrão em avaliações futuras de LLMs para GEC, suportando claramente H3. A hipótese de degradação por comprimento de sentença não se sustentou nos dados do JFLEG e, consequentemente, H4 é rejeitada. Por fim, o ranqueamento relativo entre sistemas mostrou-se altamente consistente entre CoNLL-2014 e BEA-2019, com generalização parcial para o JFLEG, confirmando H5.

Um achado não previsto pelas hipóteses originais, mas relevante, foi a falha do Grammarly em replicar o desempenho reportado por Wu et al. Nesta reprodução, ele ficou atrás de todas as três LLMs testadas no CoNLL-2014. Esse resultado ilustra um risco geral de reprodução envolvendo ferramentas comerciais fechadas e não versionadas, no qual o produto avaliado hoje pode não ser o mesmo produto avaliado originalmente.

Por fim, este trabalho disponibiliza um kit de reprodução completo, com *scripts* de execução automatizada, protocolo de consulta manual ao Grammarly, *scripts* de análise estatística e geração de figuras, e os dados brutos de todos os sistemas em formato CSV, com o objetivo de reduzir, para trabalhos futuros na área, as mesmas lacunas metodológicas que motivaram esta reprodução. Como direções de trabalho futuro, destacam-se: (i) a extensão da estratificação por comprimento de sentença para F0.5 em CoNLL-2014 e BEA-2019, não realizada nesta rodada; (ii) a introdução de uma taxonomia de tipos de erro para uma análise mais direta de *over-correction*; e (iii) a extensão do protocolo para *benchmarks* de GEC em outros idiomas, alinhada à motivação original deste trabalho em jogos educacionais multilíngues.

REFERENCES

- [1] Haoran Wu, Wenxuan Wang, Yuxuan Wan, Wenxiang Jiao, and Michael R. Lyu. 2023. ChatGPT or Grammarly? Evaluating ChatGPT on Grammatical Error Correction Benchmark. *arXiv preprint arXiv:2303.13648* (2023).
- [2] Kostiantyn Omelianchuk, Vitaliy Atrasevych, Artem N. Chernodub, and Oleksandr Skurzhashnyi. 2020. GECtoR – Grammatical Error Correction: Tag, Not Rewrite. In *Proceedings of the Fifteenth Workshop on Innovative Use of NLP for Building Educational Applications*.
- [3] Hwee Tou Ng, Siew Mei Wu, Ted Briscoe, Christian Hadiwinoto, Raymond Hendy Susanto, and Christopher Bryant. 2014. The CoNLL-2014 Shared Task on Grammatical Error Correction. In *Proceedings of the Eighteenth Conference on Computational Natural Language Learning: Shared Task*. Association for Computational Linguistics, 1–14.
- [4] Christopher Bryant, Mariano Felice, Øistein E. Andersen, and Ted Briscoe. 2019. The BEA-2019 Shared Task on Grammatical Error Correction. In *Proceedings of the Fourteenth Workshop on Innovative Use of NLP for Building Educational Applications*. 52–75.
- [5] Courtney Napoles, Keisuke Sakaguchi, and Joel Tetreault. 2017. JFLEG: A Fluency Corpus and Benchmark for Grammatical Error Correction. In *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 2, Short Papers*. 229–234.
- [6] Grammarly. 2023. Ready . . . set . . . GrammarlyGO! Our new generative AI product is now available to help you instantly compose, rewrite, ideate, and reply in your voice. Facebook. <https://www.facebook.com/grammarly/posts/ready-set-grammarlygo-our-new-generative-ai-product-is-now-available-to-help-you/6640687005950233/>